

Outline

Cuprins

1 Reamintire cursul precedent

Algoritmi nedeterminiști

- pentru anumite stări există mai multe posibilități de a continua calculul (presupunem că acestea sunt în număr finit)
- în consecință, pentru aceeași intrare, algoritmul poate da rezultate (configurații finale) diferite
- instrucțiuni specifice:
 - `choose x in S ;` – întoarce un element din S ales arbitrar
Timp de execuție (uniform): $O(1)$
 - `choose x in S s.t. B ;` – întoarce un element din S care satisface condiția B ales arbitrar
Timp de execuție (uniform): $T(B)$
- un program nedeterminist are mai multe *fire de execuție*
- un program nedeterminist rezolvă P dacă $\forall x \in P \exists$ un fir de execuție care se termină și a cărui configurație finală include $P(x)$

Algoritmi nedeterminiști pentru probleme de decizie

- Activitatea unui algoritm nedeterminist pentru o problemă de decizie:
 - “se ghicește” o anumită structură S
 - verifică dacă S satisface o proprietăți cerute de întrebare
 - dacă proprietatea este satisfăcută, se apelează instrucțiunea de terminare **success**, altfel instrucțiunea de terminare **failure**;
- Extensia limbajului:
 - success**; – semnalează terminarea verificării (și a algoritmului) cu succes
 - failure**; – semnalează terminarea fără succes

Algoritmi probabiliști

- caz particular de algoritmi nedeterminiști când există distribuție de probabilitate peste mulțimea alegerilor
- `random(n)` - întoarce un număr $x \in \{0, 1, \dots, n-1\}$ ales aleatoriu uniform (i.e. cu probabilitatea $\frac{1}{n}$)
Timp de execuție: $O(1)$

- O variabilă aleatorie este o funcție X definită peste un câmp de evenimente Ω
- Valoarea medie a lui X : $M(X) = \sum_i x_i \cdot p_i$
 Proprietăți ale mediei:
 $M(X + Y) = M(X) + M(Y)$
 $M(X \cdot Y) = M(X) \cdot M(Y)$
 (X și Y independente)

Algoritmi Monte Carlo

Pot produce rezultate incorecte cu o mică probabilitate, i.e. componenta de "output" este variabilă aleatorie.

Dacă un astfel de algoritm este executat de mai multe ori peste alegeri independente alese aleatoriu de fiecare dată, probabilitatea de eșec poate fi oricât de mică dar cu un timp de execuție mai mare. [3ex] Exemplu: test de compoziționalitate (primalitate)

Algoritmi Las Vegas

Nu produc niciodată rezultate incorecte, dar timpul poate varia de la o execuție la alta (este variabilă aleatorie).

Alegerile aleatorii sunt făcute pentru a stabili timpul mediu de execuție, care în esență este independent de intrare. [3ex] Exemplu: k -mediana

k -mediana: algoritm Las Vegas

```
randSelectRec(out a, p, q, k)
{
    j = randPartition(a, p, q);
    if (j == k) return a[j];
    if (j < k) return randSelectRec(a, j+1, q, k);
    return randSelectRec(a, p, j-1, k);
}

randSelect(out a, k)
{
    return randSelectRec(a, 0, a.size()-1, k);
}
```

randSelect: analiza 1/3

$exp-time(n, k)$ - timpul mediu pentru a găsi k -mediana într-un tablou de lungime n

$$exp-time(n) = \max_k exp-time(n, k)$$

Pentru că analizăm timpul mediu în cazul cel mai nefavorabil, presupunem apelul recursiv alege tot timpul subtabloul mai mare

$$\text{Reamintim că } M(CB) < \frac{3}{4}$$

Rezultă că dacă se împarte aleatoriu în două un tablou de lungime n , lungimea medie a celui mare subtablou este cel mult $\frac{3}{4}n$.

randSelect: analiza 2/3

Lemă 1. Lungimea medie a tabloului după i apeluri recursive este cel mult $\left(\frac{3}{4}\right)^i n$.

Demonstrarea lemei.

L_i variabila aleatorie care dă lungimea tabloului după i apeluri.

P_j variabila aleatorie care dă partea fracționară de elemente păstrate la nivelul j .

X_j variabila aleatorie care dă lungimea celui mare subtablou la nivelul j .

Avem: $L_i = n \prod_{j=1}^i P_j$, $P_j = \frac{X_j}{n}$ (presupunem că la fiecare apel recursiv se alege

subtabloul cel mai lung), $M(P_j) = M\left(\frac{X_j}{n}\right) = \frac{M(X_j)}{n} \leq \frac{\frac{3}{4}n}{n} = \frac{3}{4}$,

P_1, \dots, P_n sunt independente,

$$M(L_i) = M(n \prod_{j=1}^i P_j) = n \prod_{j=1}^i M(P_j) \leq \left(\frac{3}{4}\right)^i n$$

Acum lema e demonstrată.

randSelect: analiza 3/3

La nivelul i , numărul de operații este liniar, pp. $\leq aX_i + b$ (reamintim că X_i dă lungimea celui mare subtablou).

Fie $r \leq n$ numărul de apeluri recursive. Timpul mediu:

$$\begin{aligned} \text{exp-time}(n) &= M\left(\sum_{i=1}^r (aX_i + b)\right) \\ &= \sum_{i=1}^r M(aX_i + b) \\ &\leq \sum_{i=1}^n (aM(X_i) + b) \\ &\leq \sum_{i=1}^n \left(a\left(\frac{3}{4}\right)^i n + b\right) \\ &= an \sum_{i=1}^n \left(\frac{3}{4}\right)^i + bn \\ &\leq 4an + bn \\ &= O(n) \end{aligned}$$

2 Timpul mediu pentru algoritmi determiniști

Motivație

Fie P o problemă, $p \in P$ instanță a problemei P , A un algoritm determinist care rezolvă P .

Reamintim formula pentru complexitatea timp în cazul cel mai nefavorabil:

$$T_A(n) = \sup\{time(A, p) \mid p \in P \wedge size(p) = n\}$$

Uneori, numărul instanțelor p cu $size(p) = n$ și pentru care $time(A, p) = T_A(n)$ sau $time(A, p)$ are o valoare foarte apropiată de $T_A(n)$ este foarte mic.

Pentru aceste cazuri este preferabil să calculăm comportarea în medie a algoritmului.

Definiție

Pentru a putea calcula comportarea în medie este necesar să privim mărimea $time(A, x)$ ca fiind o variabilă aleatorie:

- o experiență = execuția algoritmului pentru o instanță x ,
- valoarea experienței = durata execuției algoritmului pentru instanța p

și să precizăm legea de repartiție a acestei variabile aleatorii. Apoi, comportarea în medie se calculează ca fiind media acestei variabile aleatoare (considerăm numai cazul timpului de execuție):

$$T_A^{med}(n) = M(\{time(A, x) \mid x \in P \wedge size(x) = n\})$$

Dacă mulțimea valorilor variabilei aleatoare $time(A, x) = \{t_0, t_1, \dots\}$ este finită sau numărabilă și probabilitatea ca $time(A, x) = t_i$ este p_i , atunci media variabilei aleatorii $time(A, _)$ (timpul mediu de execuție) este:

$$T_A^{med}(n) = \sum_i t_i \cdot p_i$$

3 Studii de caz

3.1 Prima apariție într-o listă

Problema

Considerăm problema căutării unui element într-o secvență de numere întregi:

Problema FIRST OCCURRENCE

Input: $n, a = (a_0, \dots, a_{n-1}), z$, toate numere întregi.

Output: $poz = \begin{cases} \min\{i \mid a_i = z\} & \text{dacă } \{i \mid a_i = z\} \neq \emptyset, \\ -1 & \text{altfel.} \end{cases}$

Presupunem că secvența (a_0, \dots, a_{n-1}) este memorată în tabloul **a**. Considerăm ca dimensiune a problemei P_1 numărul n al elementelor din secvența în care se caută.

Algoritm pentru FIRST OCCURRENCE

Algoritmul FOAlg descris de următorul program rezolvă FIRST OCCURRENCE:

```
//@input: un tablou a cu n elemente, z
//@output: pozitia primului element din a egal cu z,
//          -1 daca nu exista un astfel de element
i = 0;
while (a[i] != z) && (i < n-1)
    i = i+1;
if (a[i] == z) poz = i;
else poz = -1;
```

Am văzut în cursul 3 că numărul de comparații în cazul cel mai nefavorabil este n .

Timpul mediu pentru FOAlg 1/2

Mulțimea valorilor variabilei aleatorii $time(FOAlg, p)$ este $\{3i + 2 \mid 1 \leq i \leq n\}$ (s-au numărat doar atribuirile și comparațiile). În continuare trebuie să stabilim legea de repartiție. Facem următoarele presupuneri:

- probabilitatea ca $z \in \{a_0, \dots, a_{n-1}\}$ este q și
- probabilitatea ca z să apară prima dată pe poziția i este $\frac{q}{n}$ (indicii i candidează cu aceeași probabilitate pentru prima apariție a lui z).

Timpul mediu pentru FOAlg 2/2

Rezultă că probabilitatea ca $z \notin \{a_0, \dots, a_{n-1}\}$ este $1 - q$. Acum probabilitatea ca $time_{FOAlg}^n(p) = i$ ($poz = i - 1$) este $\frac{q}{n}$, pentru $2 \leq i < n$, iar probabilitatea ca $time_{FOAlg}^n(p) = n$ este $p_n = \frac{q}{n} + (1 - q)$.

Timpul mediu de execuție este:

$$\begin{aligned} exp-time(n) &= \sum_{i=2}^n p_i x_i \\ &= \sum_{i=2}^{n-1} \frac{q}{n} \cdot i + \left(\frac{q}{n} + (1 - q)\right) \cdot n \\ &= n - \frac{q}{n} - \frac{n-1}{2} \cdot q \end{aligned}$$

Pentru $q = \frac{1}{2}$ avem $exp-time(n) = \frac{3n+1}{4} - \frac{1}{2n}$.

Pentru $q = 1$ avem $exp-time(n) = \frac{n+1}{2} - \frac{1}{n}$.

3.2 Quicksort

Quicksort: descriere

Este proiectat pe paradigma divide-et-impera.

Algoritmul Quicksort *Input:* $S = \{a_0, \dots, a_{n-1}\}$ *Output:* o secvență cu elementele a_i în ordine crescătoare

1. Divizarea problemei constă în alegerea unei valori $x = a_k$ din S . Elementul x este numit *pivot*. În general se alege pivotul $x = a_0$, dar nu este obligatoriu.
2. calculează
 $S_{<} = \{a_i \mid a_i < x\}$
 $S_{=} = \{a_i \mid a_i = x\}$
 $S_{>} = \{a_i \mid a_i > x\}$
3. sortează recursiv $S_{<}$ și $S_{>}$ producând $Seq_{<}$ și $Seq_{>}$, respectiv
4. întoarce secvența $Seq_{<}, S_{=}, Seq_{>}$

Quicksort: partiționarea

Putem utiliza algoritmul Lomuto pentru k -mediană:

```
partition(out a, p, q)
{
    pivot = a[q];
    i = p - 1;
    for (j = p; j < q; ++j)
        if (a[j] <= pivot) {
            i = i + 1;
            swap(a, i, j);
        }
    swap(a, i+1, q);
    return i + 1;
}
```

Quicksort: algoritm

După sortarea recursivă a subtablourilor $a[p..k-1]$ și $a[k+1..q]$ se observă că tabloul este sortat deja. Astfel partea de asamblare a soluțiilor este vidă.

@input: $a = (a[p], \dots, a[q])$

@output: elementele secvenței a în ordine crescătoare

```
qsortRec(out a, p, q)
{
    if (p < q) {
        k = partition(a, p, q);
        qsortRec(a, p, k-1);
        qsortRec(a, k+1, q);
    }
}
```

```
qsort(out a)
{
    qsortRec(a, 0, n-1);
}
```

Quicksort: timpul în cazul cel mai nefavorabil

- dimensiune instanță: $n = a.size()$
- operații măsurate: comparații care implică elementele tabloului

Cazul cel mai nefavorabil se obține atunci când la fiecare partiționare se obține una din subprobleme cu dimensiunea 1.

Deoarece operația de partiționare necesită $q - p$ comparații, rezultă că pentru acest caz numărul de comparații este $(n-1) + (n-2) + \dots + 1 = O(n^2)$.

Acest rezultat este oarecum surprinzător, având în vedere că numele metodei este “sortare rapidă”.

Așa cum vom vedea, într-o distribuție normală cazurile pentru care QuickSort execută n^2 comparații sunt rare, fapt care conduce la o complexitate medie foarte bună a algoritmului.

Quicksort: timpul mediu

Timpul mediu pentru `qsort` este egal cu timpul mediu pentru varianta probabilistă ("randomized quicksort").

"Randomized Quicksort", intuitiv

- exemplul canonic pentru algoritmii Las Vegas

Algoritmul RQS *Input:* $S = \{a_0, \dots, a_{n-1}\}$ *Output:* elementele a_i în ordine crescătoare

1. dacă $n = 1$ întoarce a_0 , altfel *alege aleatoriu* $x = a_k \in S$
2. calculează $S_{<} = \{a_i \mid a_i < a_k\}$ $S_{=} = \{a_i \mid a_i = a_k\}$ $S_{>} = \{a_i \mid a_i > a_k\}$
3. sortează recursiv $S_{<}$ și $S_{>}$ producând $Seq_{<}$ și $Seq_{>}$, resp
4. întoarce secvența $Seq_{<}, Seq_{=}, Seq_{>}$

"Randomized Quicksort", algoritmic

Se utilizează algoritmul de partiționare aleatorie:

```
randPartition(out a, p, q) {
  if (p < q) {
    i = p + random(q - p);
    swap(a, i, q);
    return partition(a, p, q);
  }
}
```

```
randQsortRec(out a, p, q) {
  if (p < q) {
    k = randPartition(a, p, q);
    randQsortRec(a, p, k-1);
    randQsortRec(a, k+1, q);
  }
}
```

```
RQS(out a) { randQsortRec(a, 0, n-1); }
```

Analiza algoritmului RQS: varianta 1 (1/4)

Fie funcția *rank* astfel încât $a_{rank(0)} \leq \dots \leq a_{rank(n-1)}$.

Definim $X_{ij} = \begin{cases} 1 & a_{rank(i)} \text{ și } a_{rank(j)} \text{ sunt comparate} \\ 0 & \text{altfel} \end{cases}$

X_{ij} numără comparațiile dintre $a_{rank(i)}$ și $a_{rank(j)}$

X_{ij} este variabilă aleatorie și se numește indicator de variabilă

$C(n)$ - variabilă aleatorie care dă numărul de comparații

$$C(n) = \sum_{j>i} X_{ij}$$

Numărul mediu de comparații este

$$M(C(n)) = M(\sum_{i=0}^{n-1} \sum_{j>i} X_{ij}) = \sum_{i=0}^{n-1} \sum_{j>i} M(X_{ij})$$

Analiza algoritmului RQS: varianta 1 (2/4)

p_{ij} probabilitatea ca $a_{rank(i)}$ și $a_{rank(j)}$ să fie comparate într-o execuție

$$M(X_{ij}) = p_{ij} \times 1 + (1 - p_{ij}) \times 0 = p_{ij}$$

Presupunem $i < j$; $a_{rank(i)}$ și $a_{rank(j)}$ sunt comparate dacă și numai dacă primul pivot din secvența

$$a_{rank(i)}, \dots, a_{rank(j)}$$

este $a_{rank(i)}$ sau $a_{rank(j)}$. Altfel pivotul separă cele două elemente în subsecvențe diferite.

$$\text{Rezultă } p_{ij} = \frac{2}{j - i + 1}.$$

Analiza algoritmului RQS: varianta 1 (3/4)

$$\begin{aligned} \sum_{i=0}^{n-2} \sum_{j>i} p_{ij} &= \sum_{i=0}^{n-2} \sum_{j>i} \frac{2}{j - i + 1} \\ &\leq \sum_{i=0}^{n-2} \sum_{k=1}^{n-i-1} \frac{2}{k} \\ &\leq 2 \sum_{i=0}^{n-2} \sum_{k=1}^{n-i-1} \frac{1}{k} \end{aligned}$$

Analiza algoritmului RQS: varianta 1 (4/4)

Avem:

$$\sum_{k=1}^{n-i-1} \frac{1}{k} = H_{n-i-1} = \Theta(\log(n - i - 1)),$$

$$\sum_{i=0}^{n-2} \Theta(\log(n - i - 1)) = \Theta(\log(n - 1)!) = \Theta(n \log n).$$

Theorem

Numărul mediu de comparații într-o execuție al algoritmului RQS este cel mult $2nH_n = O(n \log n)$.

Exerciții

Să se determine în aceeași manieră complexitățile medii pentru insertSort și bubbleSort. Se vor considera două cazuri:

- se numără interschimbările (inversiunile) din tablou
- se numără deplasările elementelor din tablou

Indicii:

1. Probabilitatea ca perechea (i, j) ($i < j$) să formeze o inversiune este $\frac{1}{2}$.
 2. Numărul de deplasări este direct proporțional cu numărul de inversiuni.
- În care dintre cele două cazuri există diferență?

Analiza algoritmului RQS: varianta 2 (recursiv) 1/2

În continuare determinăm numărul mediu de comparații. Presupunem că $q+1-p = n$ (lungimea secvenței) și că probabilitatea ca pivotul x să fie al k -lea element este $\frac{1}{n}$ (fiecare element al tabloului poate fi pivot cu aceeași probabilitate $\frac{1}{n}$). Rezultă că probabilitatea obținerii subproblemelor de dimensiuni $k-p = i-1$ și $q-k = n-i$ este $\frac{1}{n}$. În procesul de partiționare, un element al tabloului (pivotul) este comparat cu toate celelalte, astfel că sunt necesare $n-1$ comparații. Acum numărul mediu de comparații se calculează prin formula:

Analiza algoritmului RQS: varianta 2 (recursiv) 2/2

$$\begin{aligned} \text{exp-time}(n) &= M(C(n)) = M((n-1) + \sum_{i=1}^n Y_i) \\ &= \begin{cases} (n-1) + \frac{1}{n} \sum_{i=1}^n (M(C(i-1)) + M(C(n-i))) & , \text{dacă } n \geq 1 \\ 1 & , \text{dacă } n = 0 \end{cases} \end{aligned}$$

Rezolvăm această recurență. Avem:

$$\begin{aligned} T^{\text{med}}(n) &= (n-1) + \frac{2}{n} (T^{\text{med}}(0) + \dots + T^{\text{med}}(n-1)) \\ nT^{\text{med}}(n) &= n(n-1) + 2(T^{\text{med}}(0) + \dots + T^{\text{med}}(n-1)) \end{aligned}$$

Trecem pe n în $n-1$:

$$(n-1)T^{\text{med}}(n-1) = (n-1)(n-2) + 2(T^{\text{med}}(0) + \dots + T^{\text{med}}(n-2))$$

Scădem:

$$nT^{\text{med}}(n) = 2(n-1) + (n+1)T^{\text{med}}(n-1)$$

Împărțim prin $n(n+1)$ și rezolvăm recurența obținută:

$$\begin{aligned} \frac{T^{\text{med}}(n)}{n+1} &= \frac{T^{\text{med}}(n-1)}{n} + \frac{2}{n+1} - \frac{2}{n(n+1)} \\ &= \frac{T^{\text{med}}(n-2)}{n-1} + \frac{2}{n} + \frac{2}{n+1} - \left(\frac{2}{(n-1)n} + \frac{2}{n(n+1)} \right) \\ &= \dots \\ &= \frac{T^{\text{med}}(0)}{1} + \frac{2}{1} + \dots + \frac{2}{n+1} - \left(\frac{2}{1 \cdot 2} + \dots + \frac{2}{n(n+1)} \right) \\ &= 1 + 2 \left(\frac{1}{1} + \frac{1}{2} + \dots + \frac{1}{n+1} \right) - 2 \left(\frac{1}{1 \cdot 2} + \dots + \frac{1}{n(n+1)} \right) \end{aligned}$$

Deoarece $1 + \frac{1}{2} + \dots + \frac{1}{n} = O(\log_2 n)$ și seria $\sum \frac{1}{k(k+1)}$ este convergentă (și deci șirul sumelor parțiale este mărginit), rezultă că $T(n) = O(n \log_2 n)$. Am demonstrat următorul rezultat:

Theorem

Complexitatea medie a algoritmului RQS este $O(n \log_2 n)$.

Rezolvare recurență

Notăție: $c(n) = M(C(n))$

$$\begin{aligned}c(n) &= (n-1) + \frac{2}{n}(c(0) + \dots + c(n-1)) \\ nc(n) &= n(n-1) + 2(c(0) + \dots + c(n-1))\end{aligned}$$

Trecem pe n în $n-1$:

$$(n-1)c(n-1) = (n-1)(n-2) + 2(c(0) + \dots + c(n-2))$$

Scădem:

$$nc(n) = 2(n-1) + (n+1)c(n-1)$$

Împărțim prin $n(n+1)$ și rezolvăm recurența obținută:

$$\begin{aligned}\frac{c(n)}{n+1} &= \frac{c(n-1)}{n} + \frac{2}{n+1} - \frac{2}{n(n+1)} \\ &= \frac{c(n-2)}{n-1} + \frac{2}{n} + \frac{2}{n+1} - \left(\frac{2}{(n-1)n} + \frac{2}{n(n+1)} \right) \\ &= \dots \\ &= \frac{c(0)}{1} + \frac{2}{1} + \dots + \frac{2}{n+1} - \left(\frac{2}{1 \cdot 2} + \dots + \frac{2}{n(n+1)} \right) \\ &= O(\log n) - O(1)\end{aligned}$$

3.3 Șuruburi și piulițe (Nuts and Bolts)

Domeniul problemei

- n șuruburi și n piulițe de mărimi aproximativ egale
- dar nu se poate decide care șurub (piuliță) e mai mare și care e mai mic(ă) (nu se pot compara direct două șuruburi între ele; la fel pentru piulițe)
- fiecare piuliță se potrivește exact cu un șurub
- când se compară un șurub cu o piuliță, se poate vedea dacă se potrivesc sau dacă șurubul este mai mare sau mai mic decât piuliță
- sarcina de rezolvat constă în găsirea piuliței potrivite pentru fiecare șurub

Obs. Abia în 1995 s-a proiectat un algoritm care rezolvă problema în timpul $O(n \log n)$:

Janos Komlos, Yuan Ma, and Endre Szemerédi. Sorting nuts and bolts in $O(n \log n)$ time, SIAM J. Discrete Math 11(3):347-372, 1998. Technical Report MPI-I-95-1-025, Max-Planck-Institut für Informatik, September 1995.

Versiunea simplificată

Presupunem că trebuie să găsim piulița potrivită pentru un șurub dat.

Fie $\text{cmp}(N, B)$ o funcție care întoarce:

–1 dacă piulița N este mai mică decât șurubul B ,

0 dacă piulița N se potrivește cu șurubul B ,

1 dacă piulița N este mai mare decât șurubul B .

$\text{cmp}(N, B)$ este definită pentru toate datele de intrare.

```

NutsAndBolt (NL, B)
{
    n = NL.size();
    for (i=0; i < n - 1; ++i)
        if (cmp(NL[i], B) == 0) return i;
    return n - 1;
}

```

Numărul mediu de comparații: varianta 1

Presupunem că ordinea piulițelor în lista NL (care coincide cu ordinea în care sunt testate) este o variabilă aleatorie uniformă.

Rezultă că probabilitatea ca piulița căutată să fie pe poziția i este $\frac{1}{n}$ (de ce?).

Fie $C(n)$ variabila aleatorie care dă numărul de comparații.

Presupunem că NL este nevidă și totdeauna există o piuliță care se potrivește cu B .

Valorile posibile pentru $C(n)$: $1, 2, \dots, n-1$.

Probabilitatea ca $C(n) = i$, $1 \leq i < n-1$: $\frac{1}{n}$

Probabilitatea $C(n) = n-1$: $\frac{2}{n}$

Calculul numărului mediu de comparații

$$\begin{aligned}
 M(C(n)) &= \sum_{i=1}^{n-2} i \cdot \frac{1}{n} + (n-1) \cdot \frac{2}{n} \\
 &= \sum_{i=1}^{n-1} \frac{i}{n} + \frac{n-1}{n} \\
 &= \frac{n(n-1)}{2n} + \frac{n-1}{n} \\
 &= \frac{n+1}{2} - \frac{1}{n}
 \end{aligned}$$

Numărului mediu de comparații: varianta 2 (recursiv) 1/2

Dacă $n > 1$, primul element este totdeauna testat (i.e. probabilitatea de testare a lui este 1). Reamintim că probabilitatea ca algoritmul să se oprească după primul test este $\frac{1}{n}$, rezultă că restul listei este procesată cu probabilitatea

$$1 - \frac{1}{n} = \frac{n-1}{n}.$$

Y - variabila aleatoare care dă numărul mediu de comparații $M(C(n-1))$ pentru apelul recursiv dacă prima piuliță nu e potrivită, 0 altfel.

Avem relația:

$C(1) = 0$, $C(n) = 1 + Y$ pentru $n > 0$

de unde rezultă

$$M(C(n)) = 1 + M(Y) = 1 + \frac{n-1}{n} M(C(n-1)) \text{ pentru } n > 1.$$

Numărul mediu de comparații: varianta 2 (recursiv) 2/2

Notăm $c(n) = nM(C(n))$.

Rezultă: $c(1) = 0$, $c(n) = n + c(n-1)$ pentru $n > 1$.

Avem: $c(n) = \sum_{i=2}^n i = \frac{n(n+1)}{2} - 1$.

care implică $M(C(n)) = \frac{c(n)}{n} = \frac{n+1}{2} - \frac{1}{n}$.

Cazul general, soluția 1 (naivă)

```
NutsAndBolts (NL, BL) {
  M = emptyList;  n = NL.size();
  forall B in BL {
    i = 0;
    while (i < n)
      if (cmp(NL[i], B) == 0) {
        M.pushBack([B, NL[i]]);
        i = n;
      }
  }
  return M;
}
```

Numărul de comparații în cazul cel mai nefavorabil =

Numărul mediu de comparații =

$O(n^2)$

Soluția de mai sus nu ține seama de semnificațiile valorilor -1 și 1 întoarse de `cmp`.

Cazul general, soluția 2: ideea

Soluția e de natură recursivă.

Pasul curent:

1. se alege un șurub ca pivot și se compară cu toate piulițele;
2. se ia piulița care se potrivește cu șurubul pivot și se compară cu toate celelalte șuruburi;
3. după cele $2(n-1)$ comparații, se împarte fiecare dintre cele două mulțimi (liste) în două: mulțimea șuruburilor/piulițelor mai mici, respectiv mai mari, decât șurubul/piulița pivot;

Apeluri recursive:

- un apel pentru potrivirea piulițelor mai mici cu șuruburi mai mici
- un apel pentru potrivirea piulițelor mai mari cu șuruburi mai mari

Exercițiu. Să se scrie în Alk și să se testeze algoritmul de mai sus.

Analiza în cazul cel mai nefavorabil

$$\begin{aligned}C(0) &= 0 \\C(n) &= 2n - 1 + \max_{k=1, \dots, n} (C(k-1) + C(n-k)) \\&= 2n - 1 + C(n-1)\end{aligned}$$

Rezolvând recurența, obținem

$$C(n) = \sum_{i=1}^n (2n-1) = O(n^2)$$

Numărul mediu de comparații 1/3

Presupunem că șurubul pivot este ales aleatoriu uniform.

Fie B_i al i -lea șurub în lista sortată. Similar N_j .

X_{ij} variabila aleatorie (indicatorul de variabilă) care întoarce 1 dacă B_i și N_j sunt comparate, 0 altfel.

Presupunem $i < j$. B_i și N_j sunt comparate dacă primul pivot din B_i, \dots, B_j este B_i sau B_j (de ce?).

Rezultă $M(X_{ij}) = Pr(X_{ij} = 1) = \frac{2}{j+1-i}$, $i < j$.

Relația simetrică este obținută la fel: $M(X_{ij}) = \frac{2}{i+1-j}$, $i > j$.

Dacă $i = j$, $M(X_{ij}) = 1$ (deși aceste comparații ar putea fi evitate).

Numărul mediu de comparații 2/3

Deoarece $C(n) = \sum_{i=1}^n \sum_{j=1}^n X_{ij}$, rezultă

$$\begin{aligned}M(C(n)) &= M\left(\sum_{i=1}^n \sum_{j=1}^n X_{ij}\right) \\&= \sum_{i=1}^n \sum_{j=1}^n M(X_{ij}) \\&= \sum_{i=1}^n M(X_{ii}) + 2 \sum_{i=1}^n \sum_{j=i+1}^n M(X_{ij}) \\&= n + 4 \sum_{i=1}^n \sum_{j=i+1}^n \frac{1}{j+1-i} \\&= n + 4(nH_n - 2n + H_n)\end{aligned}$$

Numărul mediu de comparații 3/3

S-a utilizat:

$$\begin{aligned}
\sum_{i=1}^n \sum_{j=i+1}^n \frac{1}{j+1-i} &= \sum_{i=1}^n \sum_{k=2}^{n+1-i} \frac{1}{k} \\
&= \sum_{k=2}^n \sum_{i=1}^{n+1-k} \frac{1}{k} \\
&= \sum_{k=2}^n \frac{n+1-k}{k} \\
&= (n+1) \sum_{k=2}^n \frac{1}{k} - \sum_{k=2}^n 1 \\
&= (n+1)(H_n - 1) - (n-1)
\end{aligned}$$

Deoarece $H_n = \sum_{k=1}^n \frac{1}{k} = \Theta(\log n)$, rezultă

$$M(C(n)) = \Theta(n \log n)$$

Numărul mediu de comparații, recursiv 1/3

Presupunem că pivot este ales aleatoriu uniform și că un șurub B este egal probabil al k -lea cel mai mic element în listă, i.e. B apare pe poziția k în lista sortată cu probabilitatea $\frac{1}{n}$.

Fie Y_k variabila aleatoare care întoarce numărul mediu de comparații dat de apelurile recursive dacă pivotul este al k -lea element, 0 altfel:

$$Y_k = \begin{cases} M(C(k-1)) + M(C(n-k)) & \text{dacă pivotul este } B_k \\ 0 & \text{altfel} \end{cases}$$

Avem

$$C(n) = 2n - 1 + \sum_{k=1}^n Y_k$$

$$M(Y_k) = \frac{1}{n} (M(C(k-1)) + M(C(n-k))).$$

Numărul mediu de comparații, recursiv 2/3

$$\begin{aligned}
M(C(n)) &= M(2n - 1 + \sum_{k=1}^n Y_k) \\
&= 2n - 1 + \sum_{k=1}^n M(Y_k) \\
&= 2n - 1 + \frac{1}{n} \sum_{k=1}^n (M(C(k-1)) + M(C(n-k))) \\
&= 2n - 1 + \frac{2}{n} \sum_{k=0}^{n-1} M(C(k))
\end{aligned}$$

de unde obținem

$$nC(n) = n(2n - 1) + 2 \sum_{k=0}^{n-1} M(C(k))$$

care implică

$$nC(n) = (n + 1)C(n - 1) + 4n - 3$$

Numărul mediu de comparații, recursiv 3/3

$$\begin{aligned} \frac{C(n)}{n+1} &= \frac{C(n-1)}{n} + \frac{4}{n+1} - \frac{3}{n(n+1)} \\ \frac{C(n-1)}{n} &= \frac{C(n-2)}{n-1} + \frac{4}{n} - \frac{3}{(n-1)n} \\ &\dots \\ \frac{C(2)}{3} &= \frac{C(1)}{2} + \frac{4}{2} - \frac{3}{1(2)} \end{aligned}$$

de unde obținem

$$\frac{C(n)}{n+1} = \frac{C(1)}{2} + \Theta(\log n) - \Theta(1)$$

care implică

$$C(n) = \Theta(n \log n)$$

Reducerea la sortare

- două șuruburi se pot compara indirect prin intermediul piulițelor (cum?)
- la fel, două piulițe se pot compara indirect prin intermediul șuruburilor (cum?)
- se definesc funcții de comparare (care este timpul pentru comparare?)
- se apelează un algoritm de sortare pentru ordonarea crescătoare a șuruburilor și, respectiv, piulițelor cu funcțiile de comparare corespunzătoare
- se întorc perechile ($BL[i]$, $NL[i]$) din listele sortate

Reducerea sortării la NutsAndBolts

- se duplică lista de sortat
- o copie joacă rolul șuruburilor, cealaltă a piulițelor
- se apelează algoritmul NutsAndBolts
- se ”contopește” lista sortată de perechi întoarsă de NutsAndBolts într-o listă sortată a elementelor inițiale

3.4 Treaps

Definiție

- combină structura de arbore binar de căutare cu cea de max-heap
- structura de arbore binar de căutare se face pe baza unei chei **key** asociate fiecărei valori
- structura de max-heap se face pe baza unei priorități **pri** asociate fiecărei valori (diferită de cheie)
- operația de căutare se face ca în arborii binari de căutare

Exemplu pe tablă.

Raimund Seidel and Cecilia R. Aragon. Randomized search trees. *Algorithmica*, 16(4/5):464-497, 1996. Available at <https://faculty.washington.edu/aragon/pubs/rst96.pdf>.

Operația de inserare

- se inserează elementul într-un nod frunză ca la arborii de căutare
- restaurare proprietate max-heap: prin operații de rotație se merge înapoi spre rădăcină până când se întâlnește un nod cu prioritate mai mare sau egală (ca la max-heap)

Exemplu pe tablă.

Operația de ștergere

- este inversă operației de inserare
- prin operații de rotație se merge spre frontieră (interschimbând de fiecare dată cu nodul copil cu prioritate mai mare)

Numărul mediu de comparații pentru căutare 1/3

- presupunem că valorile cheilor sunt $1, 2, \dots, n$
- indicator de variabilă: A_{ij} este variabila aleatorie care întoarce 1 dacă i este un predecesor al lui j
- i va avea prioritatea maximă pentru toate cheile din intervalul $[\min(i, j) .. \max(i, j)]$
- rezultă $M(A_{ij}) = \frac{1}{|i - j| + 1}$
- numărul de operații pentru un nod j (căutat/inserat/șters) este proporțional cu adâncimea în arbore a lui j
- definim $depth(j) = \sum_i A_{ij} - 1$ (se consideră că rădăcina are adâncimea 0)

Numărul mediu de comparații pentru căutare 2/3

$$\begin{aligned} M(\text{depth}(j)) &= M\left(\sum_i A_{ij} - 1\right) \\ &= \sum_i M(A_{ij}) - 1 \\ &= \sum_i \left(\frac{1}{|i-j|+1}\right) - 1 \\ &= \sum_{i=1}^j \left(\frac{1}{|i-j|+1}\right) + \sum_{i=j+1}^n \left(\frac{1}{|i-j|+1}\right) - 1 \\ &= \sum_{k=1}^j \frac{1}{k} + \sum_{k=2}^{n-j+1} \frac{1}{k} - 1 \\ &= H_j + H_{n-j+1} - 2 \end{aligned}$$

Numărul mediu de comparații pentru căutare 3/3

$\max_j \text{depth}(j)$ este atins pentru $j = \frac{n+1}{2}$, care este egală cu

$$2H_{\frac{n+1}{2}} - 2 = 2 \ln n + O(1)$$

Aceasta ne dă o margine superioară pentru numărul mediu de comparații.

Un treap aleatoriu (randomized) este un treap un obținut prin generarea aleatorie uniformă a priorităților (numere reale în $[0, 1]$) la inserare;

Dacă cheile sunt inserate în ordinea descrescătoare a priorităților, atunci rezultatul este un treap.

Analiza de mai sus este valabilă și pentru arbori binari aleatori (construiți cu inserții aleatorii, fără priorități).

Quicksort din nou

Se consideră următorul algoritm de sortare:

```
T = un arbore binar de căutare vid
inserează cheile în T în ordine aleatorie
returnează secvența în ordine a lui T
```

Să se arate că RQS poate fi ușor transformat într-un algoritm probabilist care construiește arborel binar de căutare. [2ex] Se obține aceeași complexitate medie?